

单细胞大模型专业中英文词汇表

这份词汇表面向单细胞基础模型、单细胞转录组分析和模型工程化落地。每个词条包含：

英文 / 缩写
英文全称
中文
概念解释
实际意义与经验判断

使用建议：

先掌握第 1-4 部分，能读懂单细胞数据和模型输入；
再掌握第 5-8 部分，能读懂论文和复现实验；
最后掌握第 9-12 部分，能做科研判断和工程落地。

1. 单细胞数据基础

英文/缩写	英文全称	中文	概念	实际意义与经验判断
scRNA-seq	single-cell RNA sequencing	单细胞 RNA 测序	在单细胞分辨率测量转录组表达。	所有单细胞大模型最常见输入。要先分清 raw counts、normalized counts、log-normalized data。
snRNA-seq	single-nucleus RNA sequencing	单核 RNA 测序	测量细胞核 RNA，常用于难以完整分离细胞的组织。	与 scRNA-seq 分布不同，核内转录本、低表达和细胞类型比例可能不同，模型迁移时要谨慎。
UMI	unique molecular identifier	唯一分子标识符	用随机 barcode 标记原始 RNA 分子以减少 PCR bias。	UMI count 更接近分子数；非 UMI reads 与 UMI 数据不能简单混用。
Count matrix	count matrix	计数矩阵	细胞 × 基因的原始计数矩阵。	大模型 tokenizer 常要求 raw counts；把 log-normalized 数据误当 raw counts 是高频错误。
Expression matrix	expression matrix	表达矩阵	泛指基因表达矩阵，可为 raw、normalized 或 log-transformed。	写报告时不能只说 expression matrix，必须说明具体层。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Cell	cell	细胞	表达矩阵中的一个观测单位。	单细胞数据里的“cell”可能是细胞、细胞核或 barcode 液滴。
Gene	gene	基因	表达矩阵中的特征。	不同模型使用 gene symbol、Ensembl ID 或固定 vocabulary，映射失败会直接影响模型。
Feature	feature	特征	数据矩阵中的变量，可为基因、peak、蛋白、guide RNA 等。	多组学中 feature 不一定是 gene。
Barcode	cell barcode	细胞条形码	标记单个细胞/液滴的序列。	barcode 不等于真实细胞；空液滴和 doublet 需要过滤。
Library size	library size	文库大小/总计数	每个细胞测到的总 counts。	影响表达强度；normalize_total 和 rank encoding 都在处理它带来的差异。
Sparsity	sparsity	稀疏性	表达矩阵中大量值为 0。	0 可能是真不表达，也可能是 dropout；模型和指标解释都要考虑。
Dropout	dropout	掉落/漏检	真实表达但未被测到。	单细胞数据噪声来源之一；不能把 0 值完全等同于无表达。
Doublet	doublet	双细胞/混合液滴	一个 barcode 捕获两个或多个细胞。	会形成假 cluster 或混合 marker，模型可能误学为新细胞类型。
Ambient RNA	ambient RNA	环境 RNA	细胞破裂或背景导致的游离 RNA 污染。	常让不该表达的 marker 弱阳性；注释和模型输入都受影响。
Batch	batch	批次	技术批次、测序批次、样本处理批次等。	batch 可能与疾病/样本强绑定，是数据泄漏和伪生物信号的核心来源。
Donor	donor	供体/个体	样本来源个体。	泛化评估应优先 donor-held-out，而不是随机细胞划分。
Sample	sample	样本	实验样本或生物样本。	sample 与 batch、condition、donor 常混在一起，必须审计。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Condition	condition	条件	实验或生物条件，如 healthy/disease、treated/control。	不能让 condition 与 batch 完全混杂，否则模型可能只学 batch。
Cell type	cell type	细胞类型	稳定的细胞身份类别。	标签层级要统一；T cell、CD4 T、naive CD4 T 不是同一层级。
Cell state	cell state	细胞状态	同一细胞类型内的状态差异，如 activated、cycling、disease-associated。	大模型常更擅长连续状态表示，但标签和验证更难。
Cell lineage	cell lineage	细胞谱系	细胞发育和分化关系。	解释 embedding 或 trajectory 时要结合发育生物学证据。
Marker gene	marker gene	标志基因	某细胞类型/状态中相对特异表达的基因。	一个 marker 不能决定细胞类型；至少看 marker panel 和组织背景。
Housekeeping gene	housekeeping gene	管家基因	广泛表达、维持基础功能的基因。	高表达但不一定区分细胞状态；rank-value encoding 常试图降低其支配性。

2. 数据结构与文件格式

英文/缩写	英文全称	中文	概念	实际意义与经验判断
AnnData	annotated data	注释数据对象	Python 单细胞分析常用对象。	读 h5ad 先查 <code>X/obs/var/obsm/layers/raw</code> ，不要假设 <code>X</code> 是 raw counts。
h5ad	HDF5 AnnData file	AnnData 文件	AnnData 的磁盘格式。	单细胞大模型 demo 常以 h5ad 为输入；schema 不统一是落地难点。
adata.X	AnnData X matrix	主表达矩阵	AnnData 中默认矩阵。	可能是 raw、log-normalized 或 scaled；使用前必须确认。
adata.obs	observation metadata	细胞元数据	每个细胞的标签、batch、donor 等信息。	数据泄漏检查主要看 obs。
adata.var	variable metadata	基因元数据	每个基因的 ID、symbol、HVG 标记等。	Geneformer 需要 Ensembl ID；scGPT 需要 gene_col 匹配 vocabulary。
adata.obsm	multidimensional observation	细胞多维表示	PCA、UMAP、模型 embedding 常放这	建议命名为 <code>X_pca</code> 、 <code>X_scgpt</code> 、 <code>X_geneformer</code> 等。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
	annotation		里。	
adata.layers	layers	多层表达矩阵	保存 raw counts、normalized counts 等不同矩阵。	工程项目建议明确 <code>layers["counts"]</code> ，避免覆盖原始矩阵。
adata.raw	raw snapshot	原始快照	AnnData 中保存早期表达矩阵与 var。	不一定是真 raw counts；只是一时刻快照。
Loom	loom file	Loom 文件	单细胞矩阵文件格式之一。	Geneformer tokenizer 支持 loom/h5ad；字段要求严格。
MTX	matrix market format	矩阵市场格式	10x 常见 sparse matrix 输出格式。	初始数据常为 <code>matrix.mtx + barcodes.tsv + features.tsv</code> 。
Sparse matrix	sparse matrix	稀疏矩阵	只存非零值的矩阵格式。	大数据必须用稀疏矩阵；转 dense 容易爆内存。
Gene symbol	gene symbol	基因符号	如 IL7R、MS4A1。	直观但别名多、版本不稳定。
Ensembl ID	Ensembl gene identifier	Ensembl 基因 ID	如 ENSG00000168685。	更稳定；Geneformer 等模型强依赖。
Vocabulary / Vocab	vocabulary	词表	模型能识别的基因或 token 集合。	gene coverage 是模型可用性的基础指标。
Checkpoint	model checkpoint	模型权重检查点	保存训练后参数的文件。	必须记录 checkpoint 名称、版本、来源、下载日期。
Config / args.json	configuration file	配置文件	保存模型结构和超参数。	scGPT 等模型常需要 <code>args.json + best_model.pt + vocab.json</code> 同时匹配。

3. 质量控制、预处理与传统分析

英文/缩写	英文全称	中文	概念	实际意义与经验判断
QC	quality control	质量控制	过滤低质量细胞、低表达基因和异常样本。	QC 阈值要看分布，不能机械照搬论文。
n_genes_by_counts	number of genes by counts	每细胞检测基因数	每个细胞非零基因数。	太低可能低质量，太高可能 doublet。
total_counts	total counts	总计数	每个细胞总表达量。	与 library size 类似，是测序深度 proxy。
pct_counts_mt	percentage mitochondrial	线粒体比例	线粒体基因 counts 占比。	高值可能表示细胞破损或应激，但组织差异很大。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
counts				
Ribosomal genes	ribosomal genes	核糖体基因	RPL/RPS 等。	高比例可能反映技术或生物状态，不能简单删除。
Cell cycle score	cell cycle score	细胞周期评分	S/G2M 等细胞周期状态评分。	细胞周期可能是生物信号，也可能干扰聚类。
Normalize total	normalize total counts	总量归一化	把每个细胞总 counts 缩放到固定值。	Scanpy 常用 <code>target_sum=1e4</code> ；大模型 tokenizer 未必接受 normalized 数据。
Log1p	log one plus transform	$\log(1+x)$ 转换	压缩高表达值动态范围。	常用于 PCA/传统分析；不要把 log 数据输入要求 raw counts 的 tokenizer。
Scaling	feature scaling	标准化/缩放	让基因均值为 0、方差为 1。	PCA/线性模型常用；稀疏矩阵 dense 化要小心。
HVG	highly variable genes	高变基因	选择跨细胞变化大的基因。	传统分析常用；Geneformer 明确不应先做 HVG 后 tokenization。
PCA	principal component analysis	主成分分析	线性降维。	必须保留作为大模型 embedding 的最低 baseline。
kNN graph	k-nearest neighbor graph	k 近邻图	用细胞相似性构建邻接图。	Leiden/UMAP 常基于它；n_neighbors 会影响结果。
UMAP	uniform manifold approximation and projection	UMAP 降维图	非线性二维可视化方法。	只能辅助观察，不能作为唯一证据。
t-SNE	t-distributed stochastic neighbor embedding	t-SNE 降维图	非线性可视化方法。	局部结构强，整体距离更不能过度解释。
Leiden	Leiden clustering	Leiden 聚类	图社区发现算法。	resolution 影响 cluster 数；不能把 cluster 直接等同真实细胞类型。
Louvain	Louvain clustering	Louvain 聚类	早期常用图聚类。	现多用 Leiden，但旧论文常见。
DE genes	differentially expressed genes	差异表达基因	条件或群体间表达显著差异的基因。	扰动预测常看 DE overlap；统计显著不等于生物重要。
Pseudobulk	pseudobulk	伪 bulk	按样本/条件聚合单细胞 counts	疾病差异分析常比逐细胞统计更稳健。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
			后做 bulk-like 分析。	
Ambient correction	ambient RNA correction	环境 RNA 校正	去除背景 RNA 污染。	对低表达 marker 和罕见细胞很关键。
Doublet detection	doublet detection	双细胞检测	识别混合 barcode。	doublet 会误导模型学习假细胞状态。

4. 生物统计与评价指标

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Accuracy	accuracy	准确率	总体预测正确比例。	类别不平衡时容易虚高。
Precision	precision	精确率	预测为某类中真正为该类的比例。	适合看误报。
Recall	recall	召回率	真实某类中被找出的比例。	稀有细胞类型尤其要看 recall。
F1 score	F1 score	F1 分数	precision 与 recall 的调和平均。	比 accuracy 更适合类别不平衡任务。
Macro-F1	macro-averaged F1	宏平均 F1	对每类 F1 等权平均。	细胞注释必须报告；能暴露小类失败。
Micro-F1	micro-averaged F1	微平均 F1	按样本汇总后计算 F1。	多数类占主导，接近 accuracy。
Confusion matrix	confusion matrix	混淆矩阵	真实标签与预测标签交叉表。	失败分析核心图。
ARI	adjusted rand index	调整兰德指数	聚类与真实标签一致性指标。	聚类评估常用；对随机一致性做校正。
NMI	normalized mutual information	归一化互信息	聚类与标签信息共享程度。	与 ARI 搭配看。
Silhouette score	silhouette score	轮廓系数	衡量同类近、异类远。	<code>silhouette(cell type)</code> 和 <code>silhouette(batch)</code> 含义相反，解释要小心。
kBET	k-nearest neighbor batch effect test	kNN 批次效应检验	检查局部邻域 batch 混合是否符合全局比例。	批次整合常用，但对参数和样本比例敏感。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
LSI	local inverse Simpson's index	局部逆 Simpson 指数	局部邻域标签多样性指标。	iLSI 看 batch mixing，cLSI 看 cell type purity。
iLSI	integration LSI	整合 LSI	衡量 batch 混合。	越高常表示 batch 混合越好，但不要混掉生物状态。
cLSI	cell-type LSI	细胞类型 LSI	衡量 cell type 是否混杂。	细胞类型应保持区分，cLSI 过高可能过整合。
Pearson correlation	Pearson correlation	皮尔逊相关	线性相关。	扰动表达预测常用；可能掩盖关键基因方向错误。
Spearman correlation	Spearman rank correlation	斯皮尔曼相关	排名相关。	对非线性和极值更稳健。
AUROC	area under ROC curve	ROC 曲线下面积	二分类排序能力。	类别不平衡时还需看 AUPRC。
AUPRC	area under precision-recall curve	PR 曲线下面积	不平衡二分类评估。	稀有事件预测更有意义。
Baseline	baseline model	基线模型	用于比较的简单或经典方法。	大模型必须超过合理 baseline 才能说有额外价值。
Benchmark	benchmark	基准评测	固定数据、任务、指标的系统比较。	公平 benchmark 比单个高分更重要。
Held-out split	held-out split	留出划分	训练时不使用的测试划分。	donor-held-out 比 random cell split 更可信。
Cross-validation	cross-validation	交叉验证	多次划分训练/测试评估稳定性。	小数据项目建议使用，但注意按 donor 分组。
Negative control	negative control	阴性对照	理论上不应产生正结果的对照。	判断模型是否走捷径。
Sanity check	sanity check	合理性检查	检查结果是否符合基本预期。	如打乱标签后性能应下降。

5. 深度学习与 Transformer

英文/缩写	英文全称	中文	概念	实际意义与经验判断
DL	deep learning	深度学习	用多层神经网络学习表示。	单细胞大模型是深度学习在转录组上的扩展。
Neural network	neural network	神经网络	由可学习参数组成的函数。	不要把复杂网络自动等同可解释机制。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Parameter	model parameter	模型参数	训练中更新的权重。	参数量越大不等于生物学能力越强。
Hyperparameter	hyperparameter	超参数	人为设置的训练/模型参数。	学习率、batch size、input length 会显著影响结果。
Loss	loss function	损失函数	衡量预测与目标差距。	训练目标决定模型学什么。
Epoch	epoch	训练轮次	遍历训练数据一遍。	fine-tuning 过多可能过拟合。
Batch size	batch size	批大小	一次训练/推理的样本数。	显存不足先减 batch size。
Embedding	embedding	嵌入向量	把离散对象变成连续向量。	gene/cell embedding 是下游分析的核心中间产物。
Token	token	词元	模型输入的最小单位。	单细胞中 token 可为基因、表达值、metadata、扰动条件。
Hidden state	hidden state	隐状态	模型中间层输出表示。	不同层 embedding 含义不同；最后层不一定最适合泛化。
Transformer	transformer	Transformer 模型	基于 self-attention 的深度模型架构。	单细胞模型常用，但基因没有天然语言顺序。
Attention	attention	注意力机制	让 token 根据相关性聚合其他 token 信息。	attention 权重不等于因果调控。
Self-attention	self-attention	自注意力	同一序列内部 token 相互关注。	用于学习基因共表达上下文。
Multi-head attention	multi-head attention	多头注意力	多组 attention 并行学习不同关系。	不同 head 不一定都有生物意义。
Encoder	encoder	编码器	把输入序列编码成表示。	scBERT、Geneformer 多为 encoder 路线。
Decoder	decoder	解码器	根据上下文生成输出。	生成式任务常用。
Encoder-decoder	encoder-decoder	编码器-解码器	先编码再生成/重建。	多组学转换、表达重建常见。
CLS token	classification token	分类词元	用于汇聚整个序列信息的特殊	scGPT/Geneformer V2 中常用于 cell embedding。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
			token。	
PAD token	padding token	填充词元	填充序列到同一长度。	mask/padding 错误会污染模型表示。
Mask token	mask token	遮蔽词元	训练中遮住部分输入让模型预测。	masked modeling 的基础。
MLM	masked language modeling	遮蔽语言建模	遮住 token 并预测。	scBERT/Geneformer 类模型常用思想。
Autoregressive modeling	autoregressive modeling	自回归建模	逐步预测下一个 token。	单细胞中基因无天然顺序，需明确序列顺序。
Generative pretraining	generative pretraining	生成式预训练	学习生成/补全数据模式的预训练。	scGPT 核心概念，不等于生成假细胞就是最终目的。
Fine-tuning	fine-tuning	微调	在预训练模型上继续用任务数据训练。	使用目标标签更新参数，不是 zero-shot。
Feature extraction	feature extraction	特征抽取	不更新模型，只抽 embedding 做下游任务。	课程项目最稳的上手方式。
Zero-shot	zero-shot learning	零样本学习	不用目标任务标签直接应用模型。	必须检查预训练语料重叠，不能滥称泛化。
Few-shot	few-shot learning	少样本学习	少量标签适配模型。	小样本疾病任务常见，但 split 要严格。
Transfer learning	transfer learning	迁移学习	从大数据学表示迁移到小任务。	Geneformer 的核心范式。
Overfitting	overfitting	过拟合	模型记住训练数据，泛化差。	fine-tuning 小数据时常见。
Domain shift	domain shift	域偏移	训练与测试数据分布不同。	跨组织、跨平台、跨物种时核心挑战。
OOD	out-of-distribution	分布外	测试数据超出训练分布。	unknown cell type、罕见疾病状态常属 OOD。

6. 单细胞大模型输入表示

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Tokenization	tokenization	词元化	把数据转为 token 序列。	单细胞 tokenization 是建模假设，不是小预处理。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Gene token	gene token	基因词元	每个基因作为 token。	依赖 vocabulary 和 ID 映射。
Value token	expression value token	表达值词元	表达强度离散化后的 token。	value binning 的基础。
Value binning	value binning	表达值分箱	把连续表达值分成有限档。	稳健但损失精细强度。
Value projection	value projection	表达值投影	把连续表达值投影成向量。	保留强度但对归一化敏感。
Rank-value encoding	rank-value encoding	排名-表达编码	根据细胞内基因表达优先级排序。	Geneformer 核心；抗深度差异但损失绝对强度。
Gene ranking	gene ranking	基因排序	按表达或重要性对基因排序。	top-k 太小会丢信号，太大可能引噪声。
Top-k genes	top-k genes	前 k 个基因	每细胞保留排名靠前基因。	影响模型输入长度和信息保留。
Metadata token	metadata token	元数据词元	组织、物种、batch、condition 等作为 token。	可能增强条件建模，也可能标签泄漏。
Perturbation token	perturbation token	扰动词元	药物、基因敲除等扰动条件 token。	扰动预测中常见。
Species token	species token	物种词元	表示 human/mouse 等物种。	跨物种模型需要，但 ortholog 映射仍关键。
Tissue token	tissue token	组织词元	表示组织来源。	可能帮助模型，也可能提示答案。
Batch token	batch token	批次词元	表示技术批次。	易造成泄漏；使用时必须审计。
Gene embedding	gene embedding	基因嵌入	基因的向量表示。	可做基因相似性假设，但不能直接当调控关系。
Cell embedding	cell embedding	细胞嵌入	细胞级向量表示。	聚类、注释、参考映射的核心。
CLS embedding	CLS embedding	CLS 嵌入	CLS token 的 hidden state。	常用于 cell-level 表示。
Mean pooling	mean pooling	平均池化	对 token hidden states 求平均。	简单稳健，但可能稀释关键基因。
Attention pooling	attention pooling	注意力池化	学习加权聚合 token。	更灵活，但解释更复杂。
Gene coverage	gene coverage	基因覆盖率	数据基因匹配模型词表比例。	工程落地必须报告；低覆盖会削弱结果可信度。

7. 代表模型与缩写

英文/缩写	英文全称	中文	概念	实际意义与经验判断
scFM	single-cell foundation model	单细胞基础模型	面向单细胞数据的大规模预训练模型。	不同模型任务边界差异很大，不能只看“foundation”。
FM	foundation model	基础模型	在大规模数据上预训练，可迁移到多任务的模型。	迁移能力必须用公平 benchmark 证明。
scBERT	single-cell BERT	单细胞 BERT 模型	BERT-like encoder 用于细胞类型注释。	学习监督微调和 unknown detection 的好案例。
Geneformer	Geneformer	Geneformer 模型	rank-value encoding + masked gene prediction 的网络生物学模型。	raw counts、Ensembl ID、n_counts 是关键输入要求。
Genecorpus	Genecorpus	Geneformer 预训练语料	Geneformer 的大规模单细胞语料。	预训练域决定模型泛化边界。
scGPT	single-cell GPT	单细胞 GPT 模型	生成式单细胞基础模型，支持多任务。	官方 tutorial 丰富，适合 embedding/reference mapping 入门。
scFoundation	scFoundation	单细胞基础模型 scFoundation	大规模人类单细胞转录组基础模型。	适合人类细胞/基因表示，但需检查词表和任务域。
UCE	universal cell embeddings	通用细胞嵌入	强调 zero-shot universal cell embedding。	适合作为快速 embedding benchmark 对象。
CellFM	Cell Foundation Model	细胞基础模型 CellFM	约 1 亿人类细胞预训练的大规模模型。	参数大、工程门槛高，需看成本收益。
scLong	single-cell Long-context model	长上下文单细胞模型	十亿参数级，强调长程基因上下文。	适合全基因长程依赖问题，但成本高。
Performer	Performer	Performer 模型	高效 attention 变体。	scBERT 使用，适合长序列降低 attention 成本。
RetNet	retention network	RetNet/保留网络	一类高效序列建模架构。	CellFM 相关架构关键词，理解为高效长序列替代路线。
FAISS	Facebook AI Similarity Search	向量相似搜索库	大规模最近邻搜索工具。	scGPT reference mapping 等可用它加速。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Model zoo	model zoo	模型库	官方提供的多个 checkpoint 集合。	checkpoint 选择会显著影响结果。

8. 单细胞大模型任务

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Cell type annotation	cell type annotation	细胞类型注释	给细胞预测类型标签。	必须报告 macro-F1 和混淆矩阵。
Reference mapping	reference mapping	参考映射	把 query 映射到 reference embedding/atlas。	常用 embedding + nearest neighbor，比 fine-tuning 更轻。
Batch integration	batch integration	批次整合	减少技术批次差异。	不能只追求 batch 混合，还要保留细胞类型。
Data integration	data integration	数据整合	合并多个数据集/批次/平台。	标签、平台、组织混杂时最容易误判。
Multi-omics integration	multi-omics integration	多组学整合	整合 RNA、ATAC、蛋白等模态。	特征空间不同，不能简单拼接。
Perturbation prediction	perturbation prediction	扰动预测	预测基因/药物扰动后的表达变化。	不能等同因果证明。
In silico perturbation	in silico perturbation	计算机模拟扰动	在模型中模拟删除/上调/干预基因。	候选生成工具，需要实验验证。
In silico treatment	in silico treatment	计算治疗模拟	模拟让疾病状态向健康状态移动的扰动。	靶点优先级而非临床结论。
GRN	gene regulatory network	基因调控网络	基因间调控关系网络。	attention/embedding 只能提供假设，不是直接 GRN。
Trajectory inference	trajectory inference	轨迹推断	推断细胞发育或状态连续变化路径。	embedding 好坏会影响轨迹，需生物背景验证。
Pseudotime	pseudotime	伪时间	表示细胞沿轨迹的相对进程。	不是实际时间，不能过度解释。
Cell state classification	cell state classification	细胞状态分类	区分 healthy/disease、activated/resting 等状态。	必须按 donor 或 sample split 才可信。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Disease classification	disease classification	疾病分类	基于细胞或样本表达预测疾病状态。	细胞级 accuracy 常被样本泄漏夸大。
Target discovery	therapeutic target discovery	治疗靶点发现	寻找可能干预疾病的基因/通路。	模型只能提出候选，需湿实验验证。
Expression imputation	expression imputation	表达补全	预测缺失或 dropout 表达。	可能引入模型幻觉，不能替代真实测量。
Denoising	denoising	去噪	从噪声表达中恢复信号。	去噪可能抹掉真实稀有状态。
Atlas building	atlas building	图谱构建	构建大规模参考细胞图谱。	模型可帮助映射，但 atlas 标签质量决定上限。

9. 数据泄漏、复现与公平性

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Data leakage	data leakage	数据泄漏	测试信息进入训练或调参。	foundation model 项目最危险问题之一。
Pretraining overlap	pretraining overlap	预训练重叠	测试数据可能出现在预训练语料中。	不能排除时，不要声称严格 zero-shot。
Label leakage	label leakage	标签泄漏	输入中包含直接或间接标签信息。	metadata token 和 batch/condition 绑定常见。
Batch confounding	batch confounding	批次混杂	batch 与生物条件强相关。	模型可能学技术差异而非生物学。
Donor leakage	donor leakage	供体泄漏	同一 donor 同时出现在 train/test。	疾病分类和注释任务会虚高。
Sample leakage	sample leakage	样本泄漏	同一样本细胞跨 train/test。	细胞级随机 split 的常见问题。
Train/test split	train/test split	训练/测试划分	分离训练和测试数据。	split 方式决定结论强度。
Validation set	validation set	验证集	用于调参和早停的数据。	不要用测试集调 threshold。
Test set	test set	测试集	只用于最终报告。	多次看测试集会形成隐性泄漏。
Donor-held-out	donor-held-out	供体留出	按 donor 留出测试。	比随机细胞划分更接近真实泛化。
Batch-held-out	batch-held-out	批次留出	按 batch 留出测试。	测试跨批次鲁棒性。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Study-held-out	study-held-out	研究留出	按数据集/研究留出。	最强泛化测试之一。
Reproducibility	reproducibility	可复现性	其他人能重跑并得到相近结果。	记录环境、seed、checkpoint、数据版本。
Random seed	random seed	随机种子	控制随机性的数值。	单一 seed 不够稳，关键结论建议多 seed。
Ablation	ablation study	消融实验	去掉某组件观察影响。	判断模型组件是否真的有贡献。
Failure case	failure case	失败案例	模型表现差的样本/类别。	比只展示成功图更有价值。
Error analysis	error analysis	错误分析	系统分析预测错误。	混淆矩阵、rare class、batch-specific error 必看。
Model card	model card	模型说明卡	记录模型训练、用途、限制。	工程落地应为每个 checkpoint 建 model card。
Data card	data card	数据说明卡	记录数据来源、处理、限制。	防止数据含义被误用。

10. 可解释性、因果与生物学判断

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Interpretability	interpretability	可解释性	理解模型为何给出结果。	解释性不是自动等于生物机制。
Explainability	explainability	可解释/可说明性	对模型输出提供解释。	常与 interpretability 混用。
Attribution	feature attribution	特征归因	估计输入特征对输出贡献。	对输入尺度和模型不稳定性敏感。
Integrated gradients	integrated gradients	积分梯度	一种梯度归因方法。	可用于基因贡献，但需 baseline 选择。
Occlusion	occlusion analysis	遮挡分析	移除某特征看预测变化。	类似 in silico gene deletion。
Counterfactual	counterfactual	反事实	如果改变某因素，结果如何变化。	扰动预测的核心思路，但不等于真实因果。
Causality	causality	因果性	一个因素改变导致另一个因素改变。	单细胞观测数据主要是相关，不是因果。
Correlation	correlation	相关性	两变量共同变化。	共表达不等于调控。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Co-expression	co-expression	共表达	多基因表达模式相似或共同出现。	大模型常学习它，但需区别调控关系。
Pathway enrichment	pathway enrichment	通路富集	判断基因集是否富集某通路。	常用于解释，但容易后验讲故事。
GO	gene ontology	基因本体	基因功能、过程、组分注释体系。	scLong 等可能使用 GO 图，跨物种需谨慎。
TF	transcription factor	转录因子	调控基因转录的蛋白。	低表达 TF 容易被过滤或 rank 表示低估/重排。
GRN inference	gene regulatory network inference	基因调控网络推断	从数据推断调控关系。	需要独立验证，不能只靠 attention。
Marker validation	marker validation	标志基因验证	用已知 marker 支持注释。	新状态必须结合 marker panel 和文献。
External validation	external validation	外部验证	独立数据或实验验证。	从模型发现到生物结论的关键。
Wet-lab validation	wet-lab validation	湿实验验证	CRISPR、药物、流式、染色等实验验证。	靶点发现类项目最终必需。
Biological plausibility	biological plausibility	生物学合理性	是否符合已有知识。	只能支持假设，不是决定性证据。

11. 多组学、空间与扰动

英文/缩写	英文全称	中文	概念	实际意义与经验判断
scATAC-seq	single-cell ATAC sequencing	单细胞染色质开放性测序	测量染色质可及性。	与 RNA 特征空间不同，整合需特别方法。
CITE-seq	cellular indexing of transcriptomes and epitopes by sequencing	CITE-seq	同时测 RNA 和表面蛋白。	多组学对齐和标签验证很有用。
Multitome	multitome	多组学联合测量	同一细胞多模态数据。	matched multitome 比 unmatched integration 更可靠。
Spatial transcriptomics	spatial transcriptomics	空间转录组	保留空间位置的表达测量。	单细胞大模型还需处理邻域和组织结构。
Visium	Visium	10x 空间转录组平台	spot-level 空间表达。	spot 可能含多个细胞，不等于单细胞。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Xenium	Xenium	高分辨原位平台	单细胞/亚细胞空间表达。	基因 panel 限制影响模型输入。
Perturb-seq	Perturb-seq	扰动单细胞测序	CRISPR 扰动结合 scRNA-seq。	扰动预测的重要真实验证数据。
CRISPR	clustered regularly interspaced short palindromic repeats	CRISPR	基因编辑/扰动技术。	模型靶点假设常需 CRISPR 验证。
KO	knockout	基因敲除	使基因失活。	扰动类型之一。
KD	knockdown	基因敲低	降低基因表达。	与 KO 效果不同，不能混用。
OE	overexpression	过表达	提高基因表达。	Geneformer/scGPT 可能模拟 overexpress。
Guide RNA / gRNA	guide RNA	向导 RNA	CRISPR 定位序列。	Perturb-seq 中 guide assignment 质量影响标签。
DE overlap	differential expression overlap	差异基因重叠	预测与真实 DE genes 的重叠。	扰动预测比全基因相关更关注功能变化。
Direction accuracy	direction accuracy	方向准确率	表达变化方向是否预测正确。	靶点和扰动任务非常重要。
Dose response	dose response	剂量反应	不同剂量导致的响应差异。	大多数模型对剂量泛化仍有限。
Time course	time course	时间序列	不同时间点观测。	细胞状态动态建模难点。

12. 工程化、MLOps 与落地

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Pipeline	pipeline	流水线	数据处理到模型输出的自动流程。	工程落地必须标准化。
MLOps	machine learning operations	机器学习运维	模型部署、监控、版本管理。	单细胞模型落地需要数据和模型双版本控制。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Data validation	data validation	数据校验	检查输入 schema、字段、矩阵类型。	防止 raw/log 层混用。
Schema	schema	数据模式	文件字段和格式规范。	h5ad 工程化必须定义 obs/var/layers 必填项。
Model registry	model registry	模型注册表	管理模型版本和元数据。	记录 checkpoint、vocab、license、硬件需求。
Versioning	versioning	版本管理	管理数据、代码、模型版本。	不记录版本的模型结果不可复现。
Git commit	git commit	Git 提交版本	代码版本标识。	报告中应记录官方仓库 commit 或 package version。
Environment	environment	运行环境	Python、CUDA、PyTorch、包版本。	flash-attn/CUDA 问题常导致 scGPT 等安装失败。
CUDA	compute unified device architecture	CUDA	NVIDIA GPU 计算平台。	许多大模型依赖 GPU/CUDA 版本匹配。
GPU memory	GPU memory	显存	GPU 可用内存。	batch size、input length、模型规模受它限制。
Runtime	runtime	运行时间	模型运行耗时。	工程可用性指标，不是附属信息。
Throughput	throughput	吞吐量	单位时间处理细胞数。	大规模 atlas embedding 服务必须关注。
Quantization	quantization	量化	降低参数精度以减小模型和加速。	未来落地方向，但可能影响精度。
Distillation	knowledge distillation	知识蒸馏	用大模型指导小模型。	适合把大模型能力转为轻量部署。
LoRA	low-rank adaptation	低秩适配	参数高效微调方法。	单细胞模型低资源 fine-tuning 的潜在方向。
PEFT	parameter-efficient fine-tuning	参数高效微调	只训练少量参数。	降低显存和过拟合风险。
Monitoring	monitoring	监控	跟踪模型运行和数据漂移。	新数据 gene coverage、batch drift、失败率都要监控。
Data drift	data drift	数据漂移	新数据分布与历史不同。	医院/平台/组织变化会导致模型退化。
Audit trail	audit trail	审计轨迹	保留每步记录。	临床和科研复现都需要。

英文/缩写	英文全称	中文	概念	实际意义与经验判断
Human-in-the-loop	human in the loop	人在回路	模型输出由专家审查。	单细胞注释和生物发现不应完全自动化。
License	license	许可证	代码/模型/数据使用许可。	工业落地必须检查。
Privacy	privacy	隐私	样本和患者信息保护。	单细胞数据可能含遗传和疾病敏感信息。
Federated learning	federated learning	联邦学习	数据不出机构的联合训练。	医疗多中心单细胞建模的重要方向。

13. 老手判断清单

读任何单细胞大模型论文或项目，按下面清单问一遍：

1. 输入是什么？ raw counts、log expression、ranking、binning 还是 projection？
 2. 基因 ID 是 gene symbol 还是 Ensembl ID？ gene coverage 多少？
 3. 模型训练数据覆盖我的物种、组织、疾病和平台吗？
 4. 这是 zero-shot、feature extraction、reference mapping 还是 fine-tuning？
 5. train/test split 是 random cell、donor-held-out、batch-held-out 还是 study-held-out？
 6. 是否可能有预训练语料重叠？
 7. 是否有合理 baseline？
 8. 是否报告 macro-F1、混淆矩阵、batch mixing 和失败案例？
 9. 是否只展示 UMAP？
 10. 模型关注的是 marker、batch、cell cycle、mitochondrial genes 还是疾病通路？
 11. attention/attribution 是否被过度解释为因果？
 12. 扰动预测是否有外部实验或独立数据验证？
 13. 运行时间、显存、失败细胞数是否可接受？
 14. 结论是否明确写出不能证明什么？

经验上，能把这些问题答清楚，比会背模型名字重要得多。